

Laporan Analisis Data Film Top Rated dari The Movie Database (TMDb)

Ditulis oleh

Vincent Valentino

NRP

5054251016

Kelas

N

Dosen

Dini Adni Navastara, S.Kom., M.Sc.

Aldinata Rizky Revanda, S.Kom., M.Kom.

**PRAKTIKUM DATA MINING
DEPARTEMEN TEKNIK INFORMATIKA
INSTITUT TEKNOLOGI SEPULUH NOPEMBER
2026**

1 Latar Belakang

Di tengah perkembangan era digital, film telah menjadi salah satu media hiburan yang paling diminati oleh masyarakat. Setiap tahunnya, ribuan film dari berbagai negara dengan beragam genre diproduksi dan dirilis. Kondisi tersebut menimbulkan kebutuhan akan sistem yang terstruktur untuk mengelola, mengumpulkan, serta menyajikan informasi film kepada masyarakat melalui internet.

Salah satu sistem yang banyak digunakan adalah website The Movie Database (TMDb). TMDb merupakan platform database film berbasis komunitas yang menyediakan berbagai informasi, seperti judul film, genre, tanggal rilis, pemeran, kru produksi, sinopsis, hingga rating pengguna. Data yang tersedia dapat digunakan oleh berbagai layanan dan pengguna untuk menampilkan, mencatat, serta menganalisis informasi film.

Melalui ketersediaan data yang lengkap dan terstruktur, TMDb menjadi sumber yang menarik untuk dianalisis. Analisis terhadap film-film dengan rating tertinggi atau *Top Rated* dapat memberikan gambaran mengenai karakteristik film yang memperoleh apresiasi tinggi dari penonton. Selain itu, analisis dapat mengungkap berbagai pola, seperti genre yang dominan, distribusi rating, hubungan antara budget dan revenue, tingkat perhatian pengguna, serta perubahan karakteristik film berdasarkan tahun rilis.

2 Deskripsi Dataset

Proses pengumpulan dataset dilakukan melalui dua tahap scraping. Tahap pertama bertujuan untuk memperoleh URL detail setiap film dari halaman *Top Rated* TMDb. Tahap ini diperlukan karena informasi dan fitur yang dibutuhkan tidak ditampilkan secara lengkap pada halaman utama daftar film. Setelah seluruh URL terkumpul, tahap kedua dilakukan dengan mengakses setiap halaman detail film untuk mengekstrak atribut dan informasi yang diperlukan ke dalam dataset.

Dataset hasil web scraping mencakup:

- 1.980 film, atau setara dengan 99 halaman TMDb;
- 10 kolom fitur film.

Atribut yang tersedia pada dataset dijelaskan dalam tabel berikut.

Atribut	Tipe	Keterangan
title	Nominal	Judul film.
year	Numerik diskrit	Tahun perilisian film.
runtime	Numerik diskrit	Durasi film dalam menit.
genre_1	Nominal	Genre utama film.
genre_2	Nominal	Genre tambahan.
director	Nominal	Nama sutradara.
score	Numerik diskrit	Skor film pada skala 0-100.
user_ratings	Numerik diskrit	Jumlah penilaian pengguna.
budget	Numerik kontinu	Anggaran produksi dalam USD.
revenue	Numerik kontinu	Pendapatan film dalam USD.

Seluruh film memiliki score antara 74 dan 91. Rentang yang sempit menunjukkan bahwa dataset lebih menyerupai kumpulan film berperingkat tinggi daripada sampel seluruh populasi film.

3 Statistik Deskriptif

3.1 Atribut Numerik

Tabel berikut menyajikan ringkasan statistik deskriptif numerik dari data yang dianalisis

Atribut	N	Rata-rata	Median	Modus	Standar deviasi	Minimum	Maksimum
year	1.980	1998,11	2007	2019	24,78	1902	2026
runtime	1.980	113,61	112	100	31,84	4	367
score	1.980	77,27	77	75	2,79	74	91
user_ratings	1.980	3.756,76	1.267,5	390	5.706,25	300	41.125
budget	1.269	32,56 jt	11,98 jt	15 jt	53,28 jt	1	460 jt
revenue	1.436	137,45 jt	30,60 jt	10 jt	289,74 jt	6	2,924 M

Tabel 1: Statistik deskriptif atribut numerik. Nilai budget dan revenue dinyatakan dalam USD; jt = juta dan M = miliar.

Rata-rata runtime sebesar 113,61 menit dan median 112 menit menunjukkan bahwa durasi film pada umumnya berada di sekitar dua jam. Durasi yang paling sering muncul adalah 100 menit. Dengan standar deviasi 31,84 menit dan rentang 4–367 menit, terdapat variasi durasi yang cukup besar, mulai dari film sangat pendek hingga film yang sangat panjang.

Score memiliki rata-rata 77,27, median 77, modus 75, dan standar deviasi 2,79. Nilai tersebut relatif berdekatan, sehingga score dalam dataset cenderung homogen. Hal ini wajar karena data yang digunakan berada pada rentang score 74–91.

User_ratings memiliki rata-rata 3.756,76, sedangkan mediannya hanya 1.267,5 dengan standar deviasi 5.706,25. Perbedaan yang besar ini menunjukkan bahwa hanya sebagian kecil film yang memperoleh jumlah rating sangat tinggi. Oleh karena itu, user_ratings lebih sesuai digunakan untuk melihat tingkat popularitas film daripada kualitasnya.

Budget dan revenue memiliki rata-rata yang jauh lebih tinggi dibandingkan median. Kondisi ini menunjukkan adanya sejumlah kecil film dengan biaya produksi dan pendapatan yang sangat besar (Hollywood). Dengan demikian, median lebih menggambarkan kondisi film pada umumnya, sementara rata-rata lebih banyak dipengaruhi oleh film berskala besar.

3.2 Atribut Kategorikal

Atribut	Kategori unik	Modus	Frekuensi	Persentase
genre_1	19	Drama	677	34,19%
genre_2	20	Drama	360	18,18%
director	1.206	Akira Kurosawa	15	0,76%

Tabel 2: Ringkasan statistik atribut kategorikal. Nilai tidak tersedia pada genre_2 tetap dihitung sebagai kategori dalam ringkasan awal.

Pada genre_1, Drama menjadi kategori paling dominan dengan 677 film atau 34,19% dari seluruh observasi. Animation dan Comedy berada pada urutan berikutnya dengan proporsi yang hampir sama, yaitu 11,72% dan 11,67%, kemudian Action sebesar 8,64%.

Pada genre_2, Drama kembali menjadi modus dengan 360 film atau 18,18%. Namun, terdapat 345 film atau 17,42% tanpa genre sekunder. Kedekatan jumlah tersebut menunjukkan bahwa sebagian film hanya diklasifikasikan dengan satu genre utama. Ketidadaan genre kedua tidak harus dianggap sebagai kesalahan karena film tertentu memang dapat memiliki klasifikasi yang lebih tunggal atau informasi kategorinya belum dilengkapi.


Atribut director memiliki 1.206 nama unik dari 1.978 data yang terisi. Akira Kurosawa menjadi modus dengan 15 film atau hanya 0,76% dari keseluruhan dataset, disusul Steven Spielberg dan Alfred Hitchcock dengan masing-masing 14 film. Persentase modus yang sangat kecil menandakan bahwa film-film dalam katalog tersebar pada banyak sutradara, yang dimana kebanyakan dari nama unik tersebut hanya memiliki 1 film pada *Top Rated* tersebut.

4 Penanganan Data

4.1 Perbaikan Data

Pada data awal, atribut budget dan revenue masih bertipe teks karena mengandung simbol dolar dan tanda koma. Kedua atribut tersebut seharusnya bertipe numerik agar dapat digunakan dalam perhitungan statistik. Oleh karena itu, simbol dolar dan tanda koma dihapus, kemudian nilainya dikonversi menjadi tipe float. Selain itu, nilai kosong pada atribut title, genre_1, genre_2, dan director diubah menjadi nilai NaN agar dapat dikenali sebagai missing value.

4.2 Missing Value



Gambar 1: Visualisasi missing value pada dataset.

Missing value paling banyak ditemukan pada budget dan revenue. Dari 1.980 film, budget hanya tersedia pada 1.269 film, sedangkan revenue tersedia pada 1.436 film. Selain itu, terdapat 345 nilai kosong pada genre_2 dan 2 nilai kosong pada director.

Pola missing value pada budget dan revenue terlihat serupa. Hal ini dapat menunjukkan keterkaitan pada sumber atau proses pelaporan data finansial film. Tidak semua film mempublikasikan biaya produksi dan pendapatannya. Kondisi tersebut umumnya dapat ditemukan pada film independen, film lama, film dengan distribusi terbatas, atau film yang data finansialnya tidak terdokumentasi secara lengkap pada TMDb. Missing value tetap dibiarkan sebagai NaN dan tidak diubah menjadi nol karena nilai kosong tidak berarti film tersebut tidak memiliki budget atau revenue.

Atribut	Terisi	Hilang	Persentase hilang
genre_2	1.635	345	17,42%
director	1.978	2	0,10%
budget	1.269	711	35,91%
revenue	1.436	544	27,47%

Tabel 3: Jumlah missing value pada atribut dataset.

4.3 Outlier

Outlier dideteksi menggunakan metode IQR. Hasilnya menunjukkan adanya outlier pada seluruh atribut numerik, terutama revenue sebanyak 195 data, user_ratings sebanyak 253 data, dan budget sebanyak 159 data. Outlier tersebut tidak dihapus atau dimanipulasi karena masih merepresentasikan kondisi yang valid di dunia nyata.

Atribut	Batas bawah	Batas atas	Jumlah outlier	Persentase
year	1933	2069	32	1,62%
runtime	49	177	127	6,41%
score	69	85	13	0,66%
user_ratings	-4.584,25	9.199,75	253	12,78%
budget	-43,5 jt	80,5 jt	159	12,53%
revenue	-165,41 jt	291,09 jt	195	13,58%

Tabel 4: Hasil deteksi outlier menggunakan aturan 1,5 kali IQR. Nilai budget dan revenue dinyatakan dalam USD; jt = juta.

Sebagai contoh, *The Lord of the Rings: The Return of the King* memiliki runtime 201 menit, sekitar 27 ribu user ratings, budget USD 94 juta, dan revenue sekitar USD 1 miliar. Nilai tersebut dapat dikategorikan sebagai outlier, tetapi tetap wajar untuk film berskala besar. Kasus serupa juga dapat terjadi pada film populer lainnya. Oleh karena itu, outlier dipertahankan dan atribut yang sangat miring divisualisasikan kembali menggunakan skala logaritmik.

4.4 Validitas Data


Pemeriksaan dilakukan terhadap rentang year, runtime, score, user_ratings, budget, dan revenue. Tidak ditemukan tahun di luar rentang yang ditentukan, runtime kurang dari atau sama dengan nol, score di luar skala 0-100, maupun nilai negatif pada user_ratings, budget, dan revenue. Hasil ini menunjukkan bahwa tidak terdapat nilai numerik yang aneh berdasarkan aturan pemeriksaan yang digunakan.

4.5 Duplikasi Data

Tidak ditemukan baris yang terduplikasi secara penuh. Meskipun terdapat 16 judul film yang sama, data tersebut tidak langsung dianggap sebagai duplikat karena dapat merujuk pada film yang berbeda. Contohnya adalah *All Quiet on the Western Front* versi 1930 dan versi remake tahun 2022. Oleh karena itu, data dengan judul yang sama tetap dipertahankan selama memiliki informasi film yang berbeda.


5 Visualisasi dan Interpretasi

5.1 Distribusi Atribut Numerik



Gambar 2: Distribusi atribut numerik pada dataset.


Film dalam dataset lebih banyak berasal dari tahun-tahun modern, dengan durasi yang umumnya berada di sekitar 100-120 menit. Sementara itu, `user_ratings`, `budget`, dan `revenue` memiliki distribusi miring ke kanan. Artinya, sebagian besar film memiliki nilai yang relatif rendah hingga menengah, sedangkan hanya sedikit film yang memperoleh perhatian pengguna, biaya produksi, atau pendapatan yang sangat tinggi.



Gambar 3: Distribusi user ratings, budget, dan revenue dalam skala logaritmik.

Setelah menggunakan log, sebaran ketiga atribut menjadi lebih mudah diamati. `User_ratings` menunjukkan bahwa hanya sebagian kecil film yang benar-benar mendapatkan perhatian sangat besar. Pola serupa terdapat pada `budget` dan `revenue`, yang menunjukkan adanya kelompok kecil film berskala besar di antara banyak film dengan skala produksi dan pendapatan yang lebih rendah.

5.2 Distribusi Atribut Kategorikal




Gambar 4: Jumlah film berdasarkan genre utama, genre kedua, dan sutradara.

Seperti yang dinyatakan sebelumnya drama merupakan genre yang paling banyak muncul, baik sebagai genre utama maupun genre kedua. Dominasi Drama dapat terjadi karena genre ini memiliki cakupan naratif yang luas dan mudah dipadukan dengan romance, crime, history, war, maupun family. Animation dan Comedy juga cukup dominan sebagai genre utama.

Pada atribut director, Akira Kurosawa memiliki jumlah film terbanyak dalam dataset, diikuti Steven Spielberg dan Alfred Hitchcock. Meskipun demikian, jumlah film tersebar pada banyak sutradara sehingga tidak ada satu sutradara yang mendominasi keseluruhan dataset.


5.3 Hubungan Antaratribut Numerik



Gambar 5: Korelasi antaratribut numerik.

Hubungan terkuat ditemukan antara budget dan revenue dengan nilai korelasi 0,77. Film dengan budget lebih besar cenderung menghasilkan revenue yang lebih tinggi, meskipun bukan alasan utamanya. Budget yang besar dapat mendukung skala produksi dan distribusi film, tetapi keberhasilan tetap bergantung pada penerimaan penonton.


User_ratings juga memiliki hubungan positif dengan revenue sebesar 0,63. Film yang memperoleh revenue tinggi umumnya ditonton dan dibicarakan oleh lebih banyak orang, sehingga jumlah pengguna yang memberikan rating juga meningkat. Sementara itu, hubungan score dengan budget dan revenue terlihat lemah. Hal ini menunjukkan bahwa biaya produksi dan pendapatan yang tinggi tidak selalu membuat sebuah film memperoleh score yang lebih tinggi.



Gambar 6: Perbandingan budget, revenue, dan user ratings dalam skala logaritmik.

Scatter plot memperjelas hubungan positif antara budget, revenue, dan user_ratings, tetapi titik-titiknya masih tersebar cukup luas. Beberapa film dengan budget besar tidak menghasilkan revenue yang sebanding, sedangkan beberapa film dengan budget lebih kecil dapat memperoleh hasil yang tinggi. Karena itu, budget berhubungan dengan peluang memperoleh revenue besar, tetapi bukan artinya akan berhasil.


5.4 Performa Genre



Gambar 7: Performa genre berdasarkan rata-rata score, revenue, dan jumlah film.

Dari grafik diatas, Documentary berada pada kelompok dengan rata-rata score tinggi, tetapi memiliki revenue yang relatif rendah. Film dokumenter selalu dinilai baik karena filmnya anatar membawa topik yang kuat atau merupakan dokumentasi penyanyi, walaupun itu pasarnya cenderung lebih terbatas dibandingkan film komersial berskala besar, karena membawa realisme. Action dan Science Fiction berada pada kelompok dengan rata-rata revenue tinggi. Kedua genre tersebut sering hadir sebagai film berskala besar dengan efek visual, aksi, dan dunia cerita yang dapat menarik pasar luas.

Drama memiliki jumlah film paling banyak, tetapi posisinya hanya berada di pertengahan jika dilihat dari rata-rata score dan revenue, sedangkan Mystery terlihat menonjol karena memiliki rata-rata score tertinggi sekaligus revenue yang tinggi. Cerita misteri biasanya mempertahankan rasa penasaran penonton melalui teka-teki dan pengungkapan cerita, sehingga dapat memperoleh penilaian yang baik ketika penyelesaiannya dianggap memuaskan.




Gambar 8: Distribusi score, user ratings, dan runtime pada genre utama.

Dari grafik diatas, Animation memiliki runtime yang cenderung lebih pendek dibandingkan sebagian besar genre lain, hal ini disebabkan oleh proses produksi animasi yang relatif lama sehingga durasi akan pendek tergantung kemampuan studio. Meskipun runtime lebih pendek, Animation tetap konsisten berada di antara genre dengan performa tinggi karena kekuatan visual dan kemampuannya menjangkau penonton dari berbagai usia.


Science Fiction memiliki jumlah user_ratings yang tinggi. Genre ini memiliki banyak film dan seri terkenal, seperti *Star Wars*, *Back to the Future*, dan *Blade Runner*, yang membangun komunitas penonton besar dan bertahan dalam waktu lama. Hal tersebut dapat mendorong lebih banyak pengguna untuk memberikan rating.

5.5 Performa Sutradara



Gambar 9: Sutradara dengan rata-rata revenue tertinggi, minimum tiga film.


Dari grafik diatas, James Cameron memiliki rata-rata revenue tertinggi, diikuti David Yates dan Andrew Stanton. Film-film dari sutradara tersebut banyak berkaitan dengan produksi berskala besar dan pasar internasional seperti *Avatar*.



Gambar 10: Sutradara dengan rata-rata score tertinggi, minimum tiga film.

Tosca Musk memiliki rata-rata score tertinggi pada kelompok sutradara dengan sedikitnya tiga film, diikuti Sergio Leone (*Dollars Trilogy*) dan Bong Joon Ho (*Parasite*). Untuk Tosca Musk, kemungkinan besar skornya dinaikkan secara artifisial, dikarenakan kontras dengan skornya di IMDb.

5.6 Kombinasi Genre




Gambar 11: Rata-rata score berdasarkan kombinasi genre utama dan genre kedua.

Kombinasi genre menghasilkan rata-rata score yang berbeda-beda. Science Fiction-Crime memiliki rata-rata score tertinggi yang terlihat, yaitu 82,00m, dengan Adventure-History menempati kedua

dengan 80,50. Terdapat juga beberapa kombinasi rating tinggi yang tidak ada seperti Family-Thriller dan Science Fiction-Comedy.

5.7 Perubahan Berdasarkan Tahun



Gambar 12: Jumlah film serta rata-rata score, budget, dan revenue berdasarkan tahun.

Jumlah film dalam dataset meningkat pada tahun-tahun modern dan mencapai jumlah tertinggi pada sekitar akhir 2010-an. Film lama lebih sedikit muncul karena dataset berasal dari daftar *Top Rated* yang dikumpulkan dari TMDb, bukan catatan lengkap seluruh film yang pernah diproduksi. Penurunan pada tahun terbaru juga belum tentu menunjukkan penurunan produksi karena film baru masih dapat mengumpulkan rating dan masuk ke dalam daftar pada waktu berikutnya.

Rata-rata score berubah cukup tajam pada tahun-tahun awal karena hanya sedikit film yang mewakili setiap tahun. Ketika jumlah film bertambah, rata-rata score menjadi lebih stabil di kisaran 70-an. Budget dan revenue juga cenderung meningkat seiring waktu, yang disebabkan oleh inflasi dan perubahan skala industri film.