

Laporan Praktikum 2: Preprocessing

Vincent Valentino - 5054251016 - Data Mining

1 Pendahuluan

Laporan ini menjelaskan proses preprocessing data yang dilakukan terhadap dataset `train.csv` dari kompetisi Kaggle House Prices - Advanced Regression Techniques. Dataset awal terdiri atas 1460 baris dan 81 kolom, mencakup kombinasi atribut numerik (integer/float) dan kategorikal (object), dengan kolom `SalePrice` sebagai target/label harga rumah.

Tujuan preprocessing adalah menyiapkan data agar bersih, konsisten, dan siap digunakan untuk pemodelan machine learning, melalui pembersihan data, penanganan outlier, transformasi data, dan reduksi dimensi.

2 Langkah-Langkah Praproses

2.1 Import dan Eksplorasi Awal

Dataset dimuat menggunakan `pandas.read_csv`. Kolom `Id` dihapus karena hanya berfungsi sebagai pengenalan baris dan tidak memiliki nilai informatif untuk analisis maupun pemodelan, sehingga ukuran dataset menjadi 1460 baris x 80 kolom.

Kategorikal	Numerikal
MSSubClass, MSZoning, Street, Alley, LotShape, LandContour, Utilities, LotConfig, LandSlope, Neighborhood, Condition1, Condition2, BldgType, HouseStyle, OverallQual, OverallCond, RoofStyle, RoofMatl, Exterior1st, Exterior2nd, MasVnrType, ExterQual, ExterCond, Foundation, BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2, Heating, HeatingQC, CentralAir, Electrical, KitchenQual, Functional, FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond, PavedDrive, PoolQC, Fence, MiscFeature, SaleType, SaleCondition	LotFrontage, LotArea, YearBuilt, YearRemodAdd, MasVnrArea, BsmtFinSF1, BsmtFinSF2, BsmtUnfSF, TotalBsmtSF, 1stFlrSF, 2ndFlrSF, LowQualFinSF, GrLivArea, BsmtFullBath, BsmtHalfBath, FullBath, HalfBath, Bedroom, Kitchen, TotRmsAbvGrd, Fireplaces, GarageYrBlt, GarageCars, GarageArea, WoodDeckSF, OpenPorchSF, EnclosedPorch, 3SsnPorch, ScreenPorch, PoolArea, MiscVal, MoSold, YrSold


Tabel 1: Tabel pembagian fitur-fitur

2.2 Pembersihan Data (Missing Value)

Pemeriksaan nilai hilang mengungkap 19 atribut memiliki missing value. Strategi penanganan dibedakan berdasarkan proporsi dan makna semantik nilai kosong:

1. **Penghapusan kolom** dengan proporsi missing value di atas 50%, yaitu PoolQC (99.52%), MiscFeature (96.30%), Alley (93.77%), Fence (80.75%), dan MasVnrType (59.73%), karena informasinya terlalu minim untuk diimputasi secara andal.
2. **Imputasi dengan label “None”** untuk atribut kategorikal terkait fitur rumah yang nilai NA-nya menandakan fitur tersebut memang tidak dimiliki rumah: FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond, BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2.
3. **Imputasi dengan nilai 0** untuk GarageYrBlt (tidak ada garasi) dan MasVnrArea (tidak ada masonry veneer).
4. **Imputasi median berkelompok** untuk LotFrontage, diisi menggunakan median per Neighborhood agar nilai imputasi lebih representatif terhadap konteks lokasi.
5. **Imputasi modus** untuk Electrical, karena hanya memiliki satu nilai hilang.


Visualisasi kelengkapan data (`missingno.matrix`) turut digunakan untuk mengonfirmasi pola missing value secara visual.



Gambar 1: Matriks kelengkapan data (`missingno`) sebelum pembersihan


2.3 Deteksi dan Penanganan Outlier

Karena kolom numerik yang cukup banyak, correlation matrix digunakan untuk mencari atribut yang memiliki korelasi tertinggi dengan SalePrice.




Gambar 2: Heatmap korelasi antar seluruh atribut numerik

Boxplot dibuat untuk atribut-atribut teratas (OverallQual, GarageArea, TotalBsmtSF, GrLivArea, 1stFlrSF), menunjukkan banyak outlier alami pada 1stFlrSF, GarageArea, dan TotalBsmtSF yang mencerminkan rumah besar/mahal yang memang wajar ada di pasar sehingga tidak dihapus.



Gambar 3: Boxplot atribut numerik dengan korelasi tertinggi terhadap SalePrice

Namun, scatter plot GrLivArea vs SalePrice menampilkan dua titik anomali: luas hunian (GrLivArea) sangat besar (>4000 sqft) tetapi harga jual (SalePrice) justru rendah (di bawah 300.000). Kedua baris ini dianggap anomali dan dihapus dari dataset, mengurangi jumlah baris dari 1460 menjadi 1458.



Gambar 4: Scatter plot GrLivArea vs SalePrice sebelum penanganan outlier – dua titik anomali tampak di kanan bawah

2.4 Transformasi Data

Atribut dipisahkan menjadi kelompok numerik dan kategorikal, kemudian ditransformasi dengan dua pendekatan:

- **Standarisasi (Z-score):** seluruh atribut numerik (di luar SalePrice) distandarisasi menggunakan StandardScaler agar memiliki mean = 0 dan standar deviasi = 1. Pendekatan ini dipilih karena


distribusi atribut numerik tidak sepenuhnya normal dan memiliki skala yang sangat berbeda (misalnya LotArea dalam ribuan vs OverallQual dalam skala 1–10).

- **One-Hot Encoding:** seluruh atribut kategorikal diubah menjadi variabel dummy biner.

2.5 Reduksi Dimensi

Reduksi dimensi dilakukan melalui dua tahap:

1. **Analisis korelasi antar-atribut numerik:** pasangan atribut dengan korelasi absolut lebih dari 0.8 diidentifikasi, yaitu GarageCars-GarageArea (0.887), GrLivArea-TotRmsAbvGrd (0.829), dan TotalBsmtSF-1stFlrSF (0.804). Karena korelasi tinggi ini mengindikasikan redundansi informasi (multikolinearitas), atribut kedua dari tiap pasangan (GarageArea, TotRmsAbvGrd, 1stFlrSF) dibuang.
2. **Principal Component Analysis (PCA):** PCA diterapkan pada atribut numerik yang telah distandarisasi dan direduksi berdasarkan korelasi. Scree plot kumulatif varians digunakan untuk menentukan jumlah komponen utama yang mempertahankan minimal 90% varians data.



Gambar 5: Scree plot kumulatif varians PCA – garis merah menandai ambang 90% varians

3 Hasil dari Setiap Tahapan Praproses

Tahapan	Hasil	Ukuran Data
Awal	Dataset mentah dimuat dari <code>train.csv</code>	1460 x 81
Hapus kolom Id	Kolom identifier tidak informatif dibuang	1460 x 80
Hapus kolom missing >50%	5 kolom dibuang (PoolQC, MiscFeature, Alley, Fence, MasVnrType)	1460 x 75
Imputasi missing value	19 atribut ditangani (label “None”, nilai 0, median per kelompok, modus)	1460 x 75
Penanganan outlier	2 baris anomali GrLivArea vs SalePrice dihapus	1458 x 75
Standarisasi numerik	37 atribut numerik di-Z-score-kan (mean ≈ 0 , std ≈ 1)	1458 x 37
One-Hot Encoding	38 atribut kategorikal diubah menjadi 206 kolom dummy biner	1458 x 206

Reduksi korelasi	3 atribut redundan dibuang (GarageArea, TotRmsAbvGrd, 1stFlrSF)	1458 x 34 (numerik)
PCA ($\geq 90\%$ varians)	Komponen utama numerik direduksi menjadi 23 PC	1458 x 23 (PCA)

Ringkasan numerik menunjukkan bahwa dari **37 atribut numerik** awal (di luar target), **3 atribut** dibuang karena redundansi korelasi sehingga tersisa **34 atribut numerik** hasil standarisasi. Dari **38 atribut kategorikal**, one-hot encoding menghasilkan **206 kolom dummy**. Representasi PCA menunjukkan bahwa cukup sekitar **23 komponen utama** untuk menjelaskan minimal 90% varians data numerik, mengindikasikan adanya redundansi informasi yang cukup besar pada atribut numerik asli.

4 Ringkasan Dataset Akhir

Dataset akhir hasil preprocessing disusun dengan menggabungkan tiga komponen:

1. Atribut numerik yang telah distandarisasi dan direduksi berdasarkan korelasi (34 kolom),
2. Atribut kategorikal hasil one-hot encoding (206 kolom dummy), dan
3. Kolom target SalePrice (tidak ditransformasi, agar tetap mudah diinterpretasikan sebagai harga rumah dalam satuan asli).

Ukuran akhir dataset ini adalah **1458 baris x 241 kolom**, dan disimpan ke dalam berkas dataset_final_praproses.csv. Sebagai alternatif input model dengan dimensi lebih ringkas, representasi hasil PCA (df_pca) berukuran **1458 baris x 23 kolom** juga disimpan secara terpisah.

Komponen Dataset Akhir	Jumlah Kolom
Numerik (standarisasi + reduksi korelasi)	34
Kategorikal (one-hot encoding)	206
Target (SalePrice)	1
Total	241
Alternatif: representasi PCA (df_pca)	23