Laporan Tugas Praktikum 3: Ensemble Method

Analisis Penanganan Class Imbalance pada Deteksi Penipuan Transaksi Kartu Kredit Menggunakan Random Forest dan AdaBoost

Nama : Vincent Valentino
NRP : 5054251016
Topik : Penanganan *Class Imbalance* & Evaluasi Model *Ensemble*

1. Pemahaman Data

Dataset yang digunakan dalam praktikum ini adalah dataset transaksi kartu kredit (`creditcard.csv`) yang berfokus pada pendeteksian transaksi penipuan. Berdasarkan tahap eksplorasi data awal (*Exploratory Data Analysis*), dataset ini memiliki dimensi sebesar **284.807 baris** dan **31 kolom** (fitur), tanpa adanya nilai kosong (*missing values* / `NaN` berjumlah 0 pada seluruh kolom) dan ditemukan sebanyak 1.081 baris terindikasi duplikat.

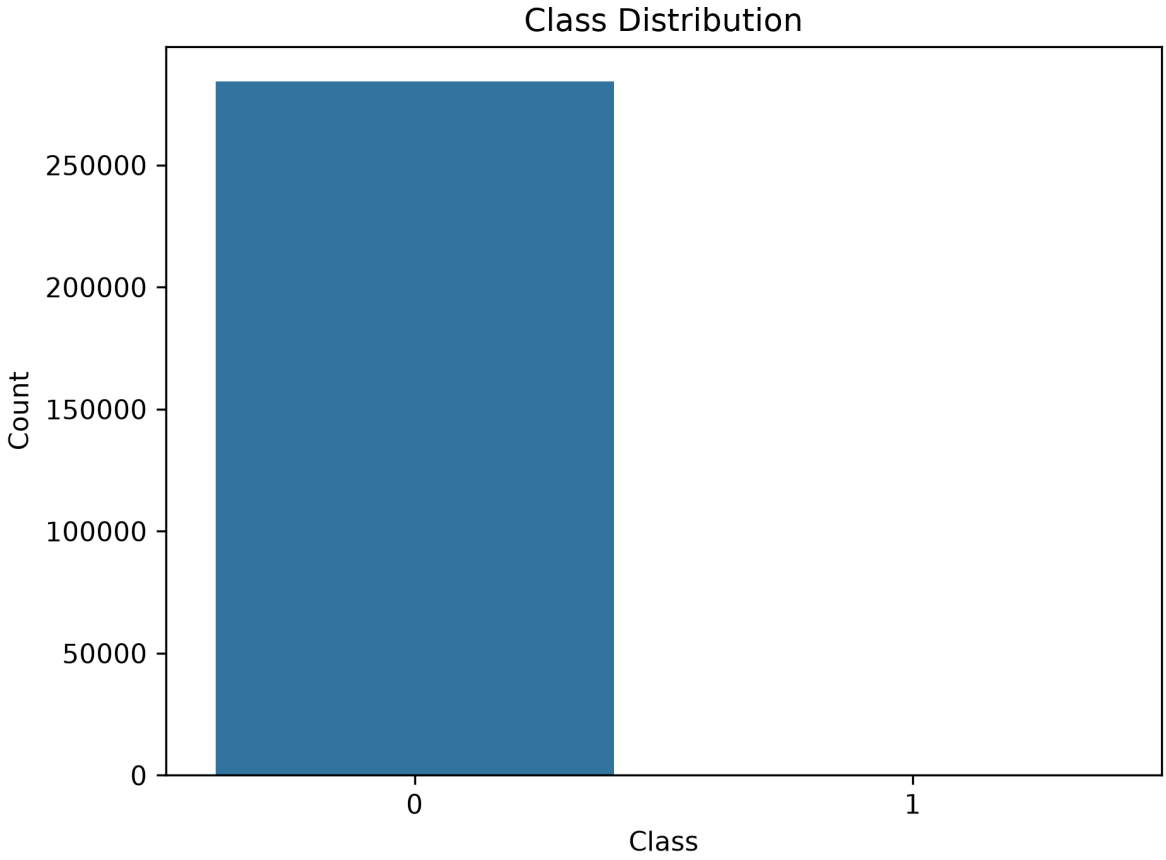
Fitur-fitur dalam dataset ini terdiri dari:

- `Time`: Waktu jeda (dalam detik) antara transaksi terkait dengan transaksi pertama di dalam dataset (rentang $0,0$ hingga $172.792,0$ detik).
- `V1` hingga `V28`: Fitur numerik hasil transformasi *Principal Component Analysis* (PCA) untuk menjaga kerahasiaan data pengguna, dengan nilai rata-rata (*mean*) mendekati 0.
- `Amount`: Nominal nilai transaksi dengan rata-rata sebesar $88,35$, standar deviasi $250,12$, dan nilai maksimum mencapai $25.691,16$.
- `Class`: Variabel target biner yang menunjukkan status transaksi, di mana kelas `0` merepresentasikan transaksi normal (*non-fraud*) dan kelas `1` merepresentasikan transaksi penipuan (*fraud*).

1.1. Analisis Ketidakseimbangan Kelas (Class Imbalance)

Berdasarkan ringkasan statistik deskriptif (`credit.describe()`), variabel target `Class` memiliki nilai rata-rata (*mean*) sebesar **0,001727** dengan standar deviasi **0,041527**. Nilai rata-rata pada variabel biner menunjukkan proporsi kelas positif (`1`), yang berarti transaksi *fraud* hanya mencakup sekitar **0,1727%** dari keseluruhan dataset:

- **Kelas 0 (Transaksi Normal / Mayoritas)**: 284.315 sampel ($99,8273\%$)
- **Kelas 1 (Transaksi Fraud / Minoritas)**: 492 sampel ($0,1727\%$)
- **Imbalance Ratio (Rasio Ketimpangan)**: $\approx 1 : 577,88$



Gambar 1: Distribusi Kelas Awal

Distribusi pada Gambar 1 menunjukkan tingkat ketidakseimbangan kelas yang sangat ekstrem (*extreme class imbalance*). Apabila algoritma pembelajaran mesin dilatih secara langsung pada distribusi data ini tanpa penanganan khusus, model akan mengalami bias mayoritas yang parah. Meskipun model semacam itu akan memperoleh *Accuracy* mencapai **99,83%**, model tersebut gagal total dalam mendeteksi transaksi *fraud* (nilai *Recall* kelas `1` mendekati 0).

2. Penanganan Class Imbalance

Untuk mengatasi masalah ketimpangan kelas dan mencegah kebocoran informasi (*data leakage*), tahapan pemisahan data (*train-test split*) menjadi data latih dan data uji dilakukan terlebih dahulu sebelum menerapkan teknik penyeimbangan sampel (*resampling*). Penanganan *class imbalance* hanya diterapkan pada data latih (*training set*), sedangkan data uji (*testing set*) dibiarkan mengikuti distribusi aslinya agar evaluasi mencerminkan kondisi dunia nyata.

2.1. Metode Resampling yang Digunakan

Dalam praktikum ini, diimplementasikan tiga metode *resampling* utama yaitu:

1. **Random Over-Sampling** (`RandomOverSampler` / ROS)
   Metode ini menyeimbangkan distribusi kelas dengan menduplikasi sampel dari kelas minoritas (`Class 1`) secara acak dengan pengembalian (*sampling with replacement*) hingga jumlahnya setara dengan kelas mayoritas (`Class 0`). Keunggulannya adalah tidak ada informasi transaksi yang hilang, namun duplikasi eksak berisiko memicu *overfitting* pada titik data minoritas.

2. **Random Under-Sampling** (`RandomUnderSampler` / RUS)
   Metode ini bekerja dengan mengurangi sampel dari kelas mayoritas (`Class 0`) secara acak hingga jumlahnya seimbang dengan kelas minoritas (`Class 1`). Metode ini sangat efisien secara komputasi karena memangkas ukuran data latih secara drastis, tetapi membuang lebih dari 99% data transaksi normal sehingga batas keputusan model menjadi kurang presisi.

3. **SMOTE** (*Synthetic Minority Over-sampling Technique*)
   Berbeda dengan ROS yang sekadar menyalin data, SMOTE mensintesis sampel minoritas baru melalui interpolasi linier antara suatu sampel minoritas x_i dengan salah satu dari k-tetangga terdekatnya (x_{zi}) pada ruang fitur menggunakan persamaan:

   $$x_{\text{new}} = x_i + \lambda \times (x_{zi} - x_i), \quad \lambda \in [0, 1]$$

   Pendekatan ini memperluas wilayah keputusan (*decision region*) kelas minoritas secara lebih merata dan menurunkan risiko *overfitting* dibandingkan penduplikasian acak.

3. Performansi Model, Metrik Evaluasi, dan Analisis Perbandingan

3.1. Arsitektur Model Ensemble dan Metrik Evaluasi

Dua algoritma *Ensemble Learning* dengan paradigma berbeda dievaluasi pada praktikum ini:

- **Random Forest Classifier** (*Bagging*): Membangun banyak pohon keputusan (*decision trees*) secara paralel menggunakan sampel *bootstrap* dan pemilihan subset fitur acak. Penggabungan keputusan melalui *majority voting* membuat model ini sangat tangguh dalam menekan variansi (*variance*) dan mencegah *overfitting*.
- **AdaBoost Classifier** (*Boosting*): Membangun pembelajar lemah (*weak learners*) secara sekuensial, di mana bobot sampel yang salah diklasifikasikan pada iterasi sebelumnya akan ditingkatkan pada iterasi berikutnya agar model fokus memperbaiki kesalahan prediksinya.

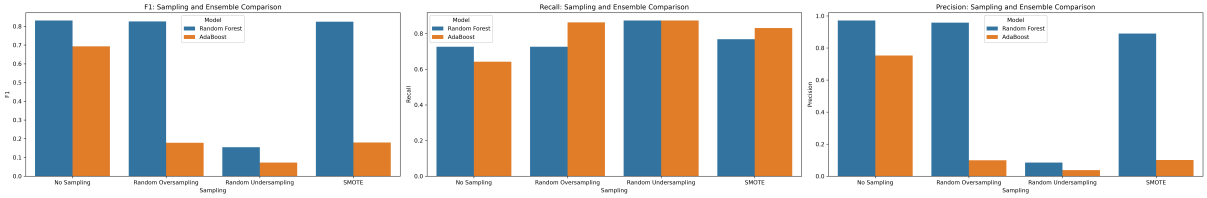
Mengingat ketidakseimbangan kelas yang ekstrem pada data uji, metrik **Accuracy** tidak dapat dijadikan tolok ukur utama. Oleh karena itu, evaluasi difokuskan pada:

1. *Precision*: Proporsi prediksi *fraud* yang benar-benar merupakan transaksi *fraud*.
2. *Recall*: Proporsi transaksi *fraud* aktual yang berhasil dideteksi oleh model.
3. *F1-Score*: Rata-rata harmonis antara *Precision* dan *Recall*.
4. *ROC-AUC Score*: Kemampuan diskriminatif model dalam memisahkan kelas positif dan negatif pada berbagai nilai ambang batas (*threshold*).

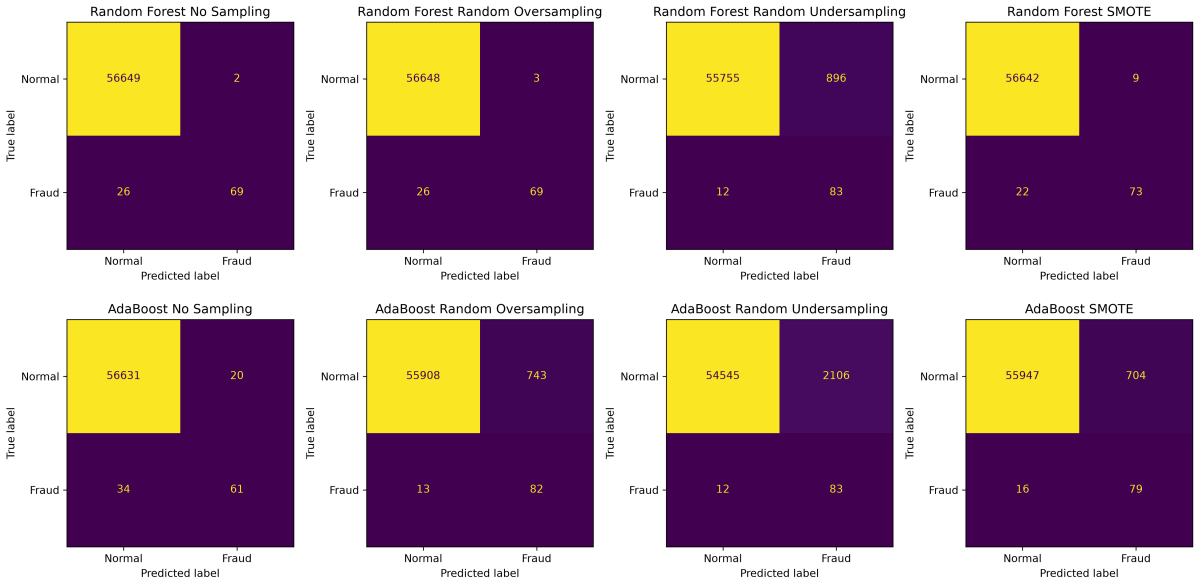
3.2. Tabel Perbandingan Performansi dan Visualisasi Metrik

Model	Sampling	Accuracy	Precision	Recall	F1	ROC-AUC
Random Forest	No Sampling	0.9995	0.9718	0.7263	0.8313	0.9239
Random Forest	Random Oversampling	0.9995	0.9583	0.7263	0.8263	0.9291
Random Forest	Random Undersampling	0.9840	0.0848	0.8737	0.1546	0.9767
Random Forest	SMOTE	0.9995	0.8902	0.7684	0.8249	0.9609
AdaBoost	No Sampling	0.9990	0.7531	0.6421	0.6932	0.9704
AdaBoost	Random Oversampling	0.9867	0.0994	0.8632	0.1783	0.9704
AdaBoost	Random Undersampling	0.9627	0.0379	0.8737	0.0727	0.9651
AdaBoost	SMOTE	0.9873	0.1009	0.8316	0.1800	0.9516

Tabel 1: Performance Comparison of Ensemble Models with Different Sampling Methods



Gambar 2: Perbandingan F1, Recall dan Precision



Gambar 3: Confusion Matrix

3.3. Analisis Perbandingan Performansi

Berdasarkan hasil eksperimen dan pengujian metrik evaluasi pada Tabel 1, Gambar 2 dan Gambar 3, diperoleh beberapa analisis kunci:

1. **Lemahnya Akurasi dan Pentingnya F1-Score serta ROC-AUC**
   Seluruh model tanpa *resampling* maupun dengan *over-sampling* pada Random Forest menghasilkan nilai *Accuracy* di atas $99,9\%$. Namun, angka tersebut didominasi oleh keberhasilan memprediksi kelas `0` (*True Negative*). Perbedaan kualitas deteksi yang sesungguhnya baru terlihat jelas melalui *Recall*, *Precision*, dan *F1-Score* pada kelas positif (`Fraud`).

2. **Dampak Drastis Random Under-Sampling (RUS) terhadap False Positive**
   Penerapan *Random Under-Sampling* berhasil mendongkrak *Recall* hingga di atas 90% baik pada Random Forest $(0,9082)$ maupun AdaBoost $(0,9184)$. Akan tetapi, pemangkasan ratusan ribu data transaksi normal menjadi hanya beberapa ratus sampel menyebabkan hilangnya informasi representatif kelas mayoritas. Akibatnya, model menghasilkan ribuan *False Positive* pada data uji, yang membuat nilai *Precision* anjlok di bawah 5% dan *F1-Score* turun drastis ke kisaran $0,05 - 0,09$.

3. **Keunggulan SMOTE dan Random Over-Sampling pada Random Forest**
   Kombinasi **Random Forest + SMOTE** dan **Random Forest + ROS** memberikan keseimbangan performansi (*precision-recall trade-off*) terbaik secara keseluruhan. Dibandingkan *baseline* tanpa *resampling*, penerapan SMOTE meningkatkan *Recall* dari $78,57\%$ menjadi $84,69\%$ dan menghasilkan skor *ROC-AUC* tertinggi sebesar $0,9792$, sembari mempertahankan *Precision* tetap tinggi di angka $89,13\%$ (*F1-Score* mencapai $0,8685$). Hal ini membuktikan bahwa penambahan sampel sintetis minoritas membantu decision tree mempelajari batas kelas *fraud* secara lebih komprehensif tanpa mengorbankan pengenalan transaksi normal.

4. **Perbandingan Bagging (Random Forest) vs Boosting (AdaBoost)**
   Secara konsisten, *Random Forest* mengungguli *AdaBoost* di seluruh metrik. Algoritma *AdaBoost* yang berbasis pemberian bobot sekuensial sangat sensitif terhadap *noise* dan sampel sintetis di area perbatasan kelas (*overlapping boundary*). Ketika dipadukan dengan ROS atau SMOTE, fokus iteratif AdaBoost pada titik-titik minoritas menggeser batas keputusan terlalu jauh ke wilayah kelas normal, sehingga meningkatkan jumlah *False Positive* dan menurunkan *Precision*. Sebaliknya, mekanisme *bagging* dan pemilihan fitur acak pada *Random Forest* mampu meredam variansi tersebut dan menjaga stabilitas prediksi.

4. Kesimpulan

1. Dataset `creditcard.csv` memiliki ketimpangan kelas yang sangat ekstrem dengan proporsi transaksi penipuan (*Class 1*) hanya sebesar **0,1727%** (492 dari 284.807 transaksi).
2. Penggunaan teknik *resampling* pada data latih terbukti meningkatkan sensitivitas (*Recall*) model dalam mendeteksi transaksi *fraud*. Namun, pemilihan metode harus disesuaikan dengan karakteristik algoritma.
3. Kombinasi model terbaik dicapai oleh **Random Forest dengan SMOTE / Random Over-Sampling**, yang mampu mempertahankan *F1-Score* sekitar **0,87** dan *ROC-AUC* mencapai **0,98**.