Laporan Tugas Praktikum 4: Association Rule

Analisis Association Learning pada Dataset Online Retail

Nama : Vincent Valentino
NRP : 5054251016

1. Pendahuluan

Association learning digunakan untuk menemukan hubungan antaritem yang sering muncul bersamaan dalam suatu transaksi, misalnya pada analisis keranjang belanja (*market basket analysis*). Pada praktikum ini digunakan dataset *Online Retail* yang mencatat transaksi sebuah toko daring di Inggris. Tujuannya adalah: (1) mengeksplorasi dan membersihkan data, (2) membentuk aturan asosiasi beserta evaluasinya, dan (3) menyimpulkan pola yang ditemukan.

2. Eksplorasi Data

2.1. Gambaran umum dataset

Dataset berisi 541.909 baris dan 8 kolom, yaitu `InvoiceNo`, `StockCode`, `Description`, `Quantity`, `InvoiceDate`, `UnitPrice`, `CustomerID`, dan `Country`. Setiap baris mewakili satu jenis produk dalam satu invoice. Periode transaksi berlangsung dari 1 Desember 2010 hingga 9 Desember 2011.

Kolom	Tipe	Keterangan
InvoiceNo	string	Nomor invoice, 25.900 nilai unik, awalan “C” menandakan pembatalan
StockCode	string	Kode produk, 4.070 nilai unik
Description	string	Nama produk, 4.223 nilai unik, 1.454 kosong
Quantity	integer	Jumlah barang; rentang −80.995 sampai 80.995, median 3
InvoiceDate	string	Waktu transaksi
UnitPrice	float	Harga satuan, median 2,08, minimum −11.062,06
CustomerID	float	ID pelanggan, 135.080 kosong
Country	string	Negara, 38 nilai unik, 495.478 baris dari United Kingdom

Tabel 1: Struktur dan ringkasan kolom dataset.

2.2. Kualitas data

Pemeriksaan awal menunjukkan beberapa hal yang perlu diperhatikan:

- Duplikasi: terdapat 5.268 baris duplikat penuh.
- Nilai hilang: `Description` kosong pada 1.454 baris (seluruhnya berharga satuan 0), dan `CustomerID` kosong pada 135.080 baris.
- Nilai tidak wajar: `Quantity` dan `UnitPrice` memiliki nilai negatif. Terdapat 10.624 baris dengan `Quantity` ≤ 0, yang sebagian besar berkaitan dengan invoice pembatalan (awalan “C”, 9.288 baris dari 3.836 invoice).
- Distribusi: rata-rata `Quantity` 9,55 dengan simpangan baku 218,08, menandakan adanya *outlier* ekstrem (misalnya pesanan grosir ±80.995 unit).

Produk yang paling sering muncul adalah *White Hanging Heart T-Light Holder* (2.327 baris setelah pembersihan), *Jumbo Bag Red Retrospot* (2.115), dan *Regency Cakestand 3 Tier* (2.019).

3. Pembersihan dan Praproses Data

Analisis asosiasi hanya membutuhkan informasi *keranjang* dan *item*, sehingga hanya kolom `InvoiceNo`, `Description`, dan `Quantity` yang dipertahankan. Tahapan pembersihan:

1. Menghapus baris dengan `Description` kosong, karena item tanpa nama tidak dapat diidentifikasi.
2. Menghapus invoice yang diawali huruf "C" (transaksi pembatalan), karena bukan merupakan pembelian.
3. Menghapus sisa nilai kosong dan baris dengan `Quantity` ≤ 0.

Tahap	Baris	Invoice	Baris dihapus
Data awal	541.909	25.900	—
Hapus `Description` kosong	540.455	24.446	1.454
Hapus invoice pembatalan ("C")	531.167	20.610	9.288
Hapus `Quantity` ≤ 0	530.693	20.136	474

Tabel 2: Dampak setiap tahap pembersihan.

Setelah pembersihan tersisa 530.693 baris dan 20.136 invoice, atau berkurang sekitar 2,1% baris dan 22,3% invoice. Data kemudian ditransformasikan menjadi daftar transaksi (satu daftar nama produk untuk tiap invoice) dan di-*encode* dengan `TransactionEncoder` menghasilkan 4.077 produk unik. Setiap keranjang rata-rata memuat 25,8 produk berbeda, dengan median 15 produk. Keranjang terbesar mencakup 1.108 produk, sedangkan 1.798 keranjang hanya terdiri dari satu produk.

4. Hasil Association Learning

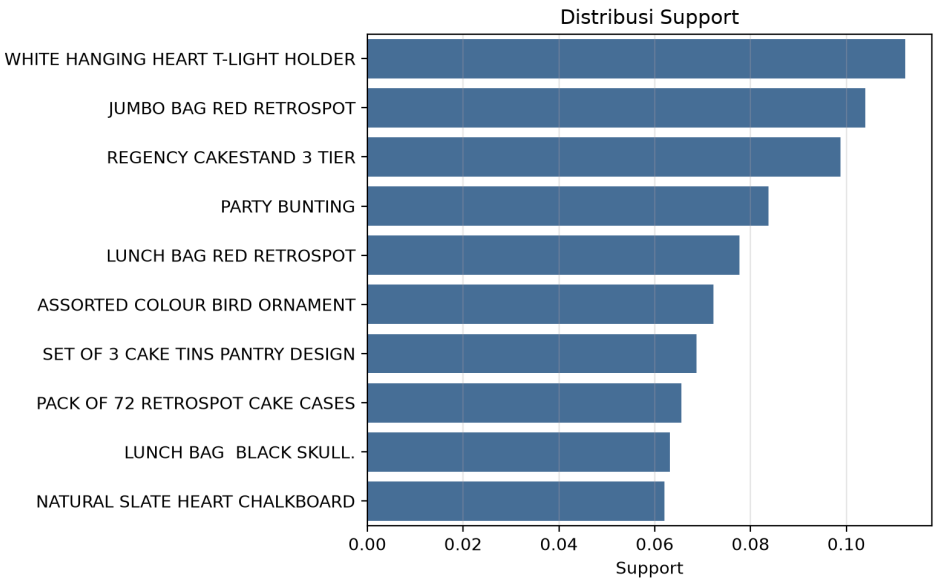
4.1. Parameter

Algoritma Apriori dijalankan dengan `min_support = 0,01` (itemset muncul pada minimal ±201 invoice). Aturan dibentuk dengan metrik *confidence* dan ambang `min_threshold = 0,5`, lalu diurutkan berdasarkan *lift*. Ukuran evaluasi yang digunakan:

- Support: proporsi transaksi yang memuat seluruh item dalam aturan.
- Confidence: peluang konsekuen dibeli jika antecedent sudah dibeli.
- Lift: rasio confidence terhadap support konsekuen; lift > 1 menunjukkan asosiasi positif.

4.2. Frequent itemset

Dari 4.077 produk unik, hanya 804 produk yang memenuhi support minimum. Apriori menghasilkan 1.854 frequent itemset dengan 804 itemset berukuran 1, 818 berukuran 2, 215 berukuran 3, 16 berukuran 4, dan 1 berukuran 5.



Gambar 1: Sepuluh produk dengan support tertinggi.

Produk terlaris adalah *White Hanging Heart T-Light Holder* dengan support 11,22%, diikuti *Jumbo Bag Red Retrospot* (10,39%) dan *Regency Cakestand 3 Tier* (9,88%). Tidak ada produk yang muncul pada lebih dari 12% invoice, sehingga ambang 1% sudah cukup rendah untuk menangkap pola yang bermakna.

4.3. Aturan asosiasi

Terbentuk 841 aturan asosiasi dari 423 itemset unik (setiap itemset menghasilkan beberapa aturan dengan arah berbeda). Ukuran aturan (jumlah item antecedent + consequent) menghasilkan 251 aturan berukuran 2, 476 berukuran 3, 96 berukuran 4, dan 18 berukuran 5.

Metrik	Rata-rata	Min	Maks
Support	0,0135	0,0100	0,0410
Confidence	0,650	0,500	0,959
Lift	17,53	4,82	80,22

Tabel 3: Ringkasan statistik 841 aturan asosiasi.

4.3.1. Tiga aturan dengan lift tertinggi

#	Antecedent	Consequent	Support	Conf.	Lift
1	Herb Marker Rosemary + Herb Marker Parsley	Herb Marker Thyme	0,0101	0,944	80,22
2	Herb Marker Thyme	Herb Marker Rosemary + Herb Marker Parsley	0,0101	0,857	80,22
3	Herb Marker Rosemary	Herb Marker Thyme + Herb Marker Parsley	0,0101	0,846	79,96

Tabel 4: Tiga aturan teratas berdasarkan lift (`top_3`).

Ketiganya melibatkan penanda tanaman herba (*Herb Marker*: Rosemary, Parsley, Thyme). Pada aturan 1, 94,4% pelanggan yang membeli Rosemary dan Parsley juga membeli Thyme, padahal peluang Thyme muncul secara umum hanya 1,18%. Lift sebesar 80,22 berarti kemungkinan membeli Thyme menjadi sekitar 80 kali

lebih besar dibanding peluang dasarnya. Support aturan ini hanya 1,01% (±203 invoice), sehingga polanya kuat tetapi menyangkut segmen pembeli yang kecil.

4.3.2. Aturan menonjol lainnya

Lift tinggi didominasi kelompok *Herb Marker* (26 aturan memuat produk ini, lift 72–80). Di luar kelompok tersebut, aturan lift tertinggi adalah:

Antecedent	Consequent	Support	Conf.	Lift
Regency Tea Plate Green + Roses	Regency Tea Plate Pink	0,0127	0,799	52,77
Regency Tea Plate Pink + Roses	Regency Tea Plate Green	0,0127	0,948	50,10
Set of 3 Wooden Tree Decorations	Set of 3 Wooden Stocking Decoration	0,0109	0,747	47,18
Regency Sugar Bowl Green	Regency Milk Jug Pink	0,0121	0,755	46,19
Poppy's Playhouse Bedroom + Kitchen	Poppy's Playhouse Livingroom	0,0111	0,716	43,93

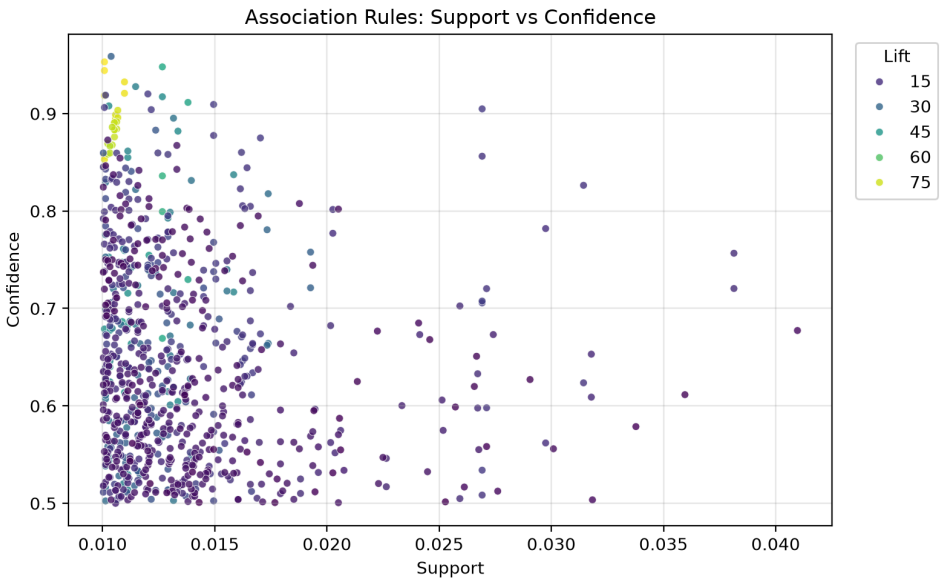
Tabel 5: Aturan lift tertinggi di luar kelompok Herb Marker.

Berdasarkan support tertinggi (aturan yang paling sering terjadi), diperoleh:

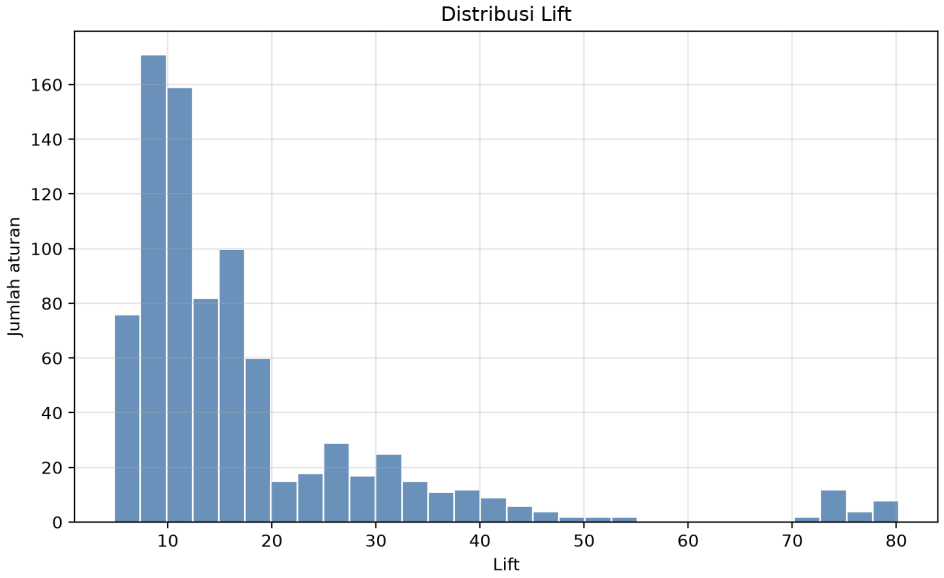
Antecedent	Consequent	Support	Conf.	Lift
Jam Making Set Printed + Shoulder Bag Suki Design	Dotcom Postage	0.0103	0.958	27.266
Jumbo Bag Pink Polkadot	Jumbo Bag Red Retrospot	0,0410	0,677	6,52
Green Regency Teacup and Saucer	Roses Regency Teacup and Saucer	0,0381	0,757	14,29
Jumbo Storage Bag Suki	Jumbo Bag Red Retrospot	0,0360	0,611	5,89
Jumbo Shopper Vintage Red Paisley	Jumbo Bag Red Retrospot	0,0338	0,579	5,57
Lunch Bag Black Skull	Lunch Bag Red Retrospot	0,0318	0,504	6,48
Alarm Clock Bakelike Green	Alarm Clock Bakelike Red	0,0318	0,653	12,51

Tabel 6: Aturan dengan support tertinggi.

Aturan dengan confidence tertinggi (0,959) adalah *Jam Making Set Printed* + *Shoulder Bag Suki Design* → *Dotcom Postage* (lift 27,27). Item "Dotcom Postage" sebenarnya bukan produk fisik melainkan biaya pengiriman, sehingga aturan ini kurang bermakna untuk rekomendasi produk.



Gambar 2: Sebaran support dan confidence seluruh aturan; warna menunjukkan lift.



Gambar 3: Distribusi nilai lift dari 841 aturan.

4.4. Analisis evaluasi

Support. Seluruh aturan memiliki support antara 1,0% dan 4,1% (rata-rata 1,35%). Nilai ini kecil secara absolut karena katalog sangat beragam (4.077 produk), tetapi sudah wajar untuk data ritel dengan ribuan SKU. Konsekuensinya, aturan berlaku bagi sebagian kecil transaksi, sehingga lebih cocok untuk strategi bundling atau rekomendasi produk tertentu daripada kebijakan toko secara menyeluruh.

Confidence. Rata-rata confidence 65% dan 99 aturan memiliki confidence ≥ 80%. Artinya, jika antecedent dibeli, konsekuen sangat mungkin ikut dibeli. Namun confidence saja dapat menyesatkan untuk konsekuen yang populer, misalnya *Jumbo Bag Red Retrospot* (support 10,4%) yang muncul sebagai konsekuen pada banyak aturan.

Lift. Seluruh aturan memiliki lift > 1 (minimum 4,82, median 12,66) dan 575 aturan memiliki lift > 10, sehingga hubungan antaritem jauh melampaui kejadian acak. Lift sangat tinggi (> 40) umumnya terjadi pada produk yang support-nya rendah (±1,2%) namun hampir selalu dibeli bersamaan, yaitu produk satu set.

Aturan berlift lebih rendah (5–7) justru mempunyai support terbesar, misalnya pada keluarga *Jumbo Bag* dan *Lunch Bag*, yang berarti hubungan lebih lemah tetapi menyangkut lebih banyak pelanggan.

Redundansi. Aturan bersifat simetris dan berulang, karena satu itemset menghasilkan beberapa aturan (841 aturan dari 423 itemset). Karena itu tiga aturan lift tertinggi sebenarnya merepresentasikan satu pola yang sama, yaitu kelompok Herb Marker, bukan tiga pola yang berbeda.

5. Kesimpulan

1. **Pola utama**: pelanggan cenderung membeli produk dalam satu keluarga atau koleksi, yang berbeda warna atau desain. Contohnya adalah *Herb Marker* (Rosemary, Parsley, Thyme, Mint, Basil), *Regency Tea Plate/ Teacup* (Green, Pink, Roses), *Charlotte Bag*, *Jumbo Bag*, *Lunch Bag*, dan *Poppy's Playhouse*. Pola ini juga terlihat pada itemset terbesar (5 item) yang seluruhnya berupa varian *Charlotte Bag*.
2. Pola lintas kategori sangat jarang muncul, hampir semua aturan terjadi antarvarian dalam satu produk. Hal ini sejalan dengan karakter pelanggan toko ini yang banyak berupa pembeli grosir yang memesan satu rangkaian produk sekaligus.
3. **Implikasi bisnis**: toko dapat membuat paket (*bundle*) set produk sejenis, merekomendasikan varian lain saat salah satunya dibeli, dan menata produk satu keluarga berdekatan di katalog.
4. **Keterbatasan**: (a) aturan berlift tinggi bersupport rendah sehingga hanya mewakili segmen kecil; (b) terdapat item non-produk seperti *Dotcom Postage* yang sebaiknya dikeluarkan pada analisis lanjutan; (c) penamaan produk yang tidak konsisten (spasi ganda, titik di akhir) dapat memecah item yang sama; dan (d) aturan banyak yang redundan. Pengembangan selanjutnya dapat berupa penurunan `min_support` untuk menggali produk niche, penyaringan aturan redundan, analisis per negara, serta pembandingan dengan algoritma FP-Growth.