Laporan Tugas Praktikum 4: Association Rule

Analisis Association Learning pada Dataset Online Retail

Nama : Vincent Valentino
NRP : 5054251016

1. Pendahuluan

Laporan ini membahas penerapan *Sequential Pattern Mining* pada dataset *Online Retail* (transaksi sebuah toko online di Inggris, Desember 2010 sampai Desember 2011). Tujuannya adalah menemukan pola pembelian berurutan, yaitu produk yang cenderung dibeli pelanggan setelah membeli produk tertentu.

2. Eksplorasi Data

2.1. Gambaran Awal Dataset

Dataset berisi 541.909 baris dan 8 kolom, yaitu `InvoiceNo`, `StockCode`, `Description`, `Quantity`, `InvoiceDate`, `UnitPrice`, `CustomerID`, dan `Country`. Setiap baris mewakili satu jenis produk dalam satu invoice. Periode transaksi berlangsung dari 1 Desember 2010 hingga 9 Desember 2011.

Kolom	Tipe	Keterangan
InvoiceNo	string	Nomor invoice, 25.900 nilai unik, awalan “C” menandakan pembatalan
StockCode	string	Kode produk, 4.070 nilai unik
Description	string	Nama produk, 4.223 nilai unik, 1.454 kosong
Quantity	integer	Jumlah barang; rentang −80.995 sampai 80.995, median 3
InvoiceDate	string	Waktu transaksi
UnitPrice	float	Harga satuan, median 2,08, minimum −11.062,06
CustomerID	float	ID pelanggan, 135.080 kosong
Country	string	Negara, 38 nilai unik, 495.478 baris dari United Kingdom

Tabel 1: Struktur dan ringkasan kolom dataset.

Hasil eksplorasi menunjukkan beberapa masalah kualitas data:

Masalah	**Jumlah**	**Keterangan**
Baris duplikat	5.268	Baris identik pada seluruh kolom
`Description` kosong	1.454	Produk tanpa nama tidak dapat dijadikan item
`CustomerID` kosong	135.080	Sekitar 25% data; sequence per pelanggan tidak dapat dibentuk
`Quantity` negatif	ada	Nilai minimum −80.995, indikasi retur/pembatalan
`UnitPrice` negatif	ada	Nilai minimum −11.062,06, indikasi koreksi/penyesuaian

Tabel 2: Masalah kualitas data pada dataset mentah

2.2. Pembersihan

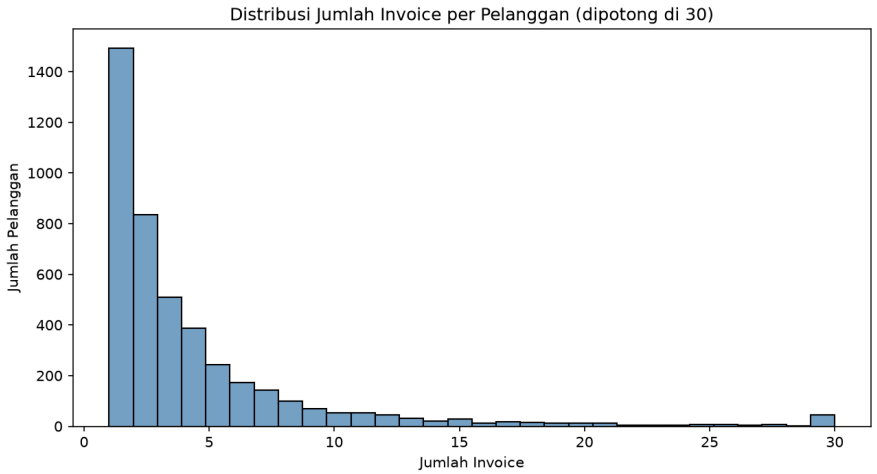
Pembersihan dilakukan berurutan sebagai berikut:

1. Menghapus baris dengan `Description` kosong, menghapus duplikat, dan merapikan spasi pada nama produk.
2. Menghapus invoice pembatalan, yaitu `InvoiceNo` yang diawali huruf "C".
3. Menyisakan baris dengan `Quantity` > 0.
4. Menghapus baris tanpa `CustomerID`, lalu mengubah tipenya menjadi bilangan bulat. Langkah ini wajib karena pola berurutan dibentuk per pelanggan.

Setelah pembersihan, data tersisa 392.732 baris dan 18.536 invoice (dari 541.909 baris dan 25.900 invoice). Dengan demikian sekitar 27,5% baris dan 28,4% invoice dibuang.

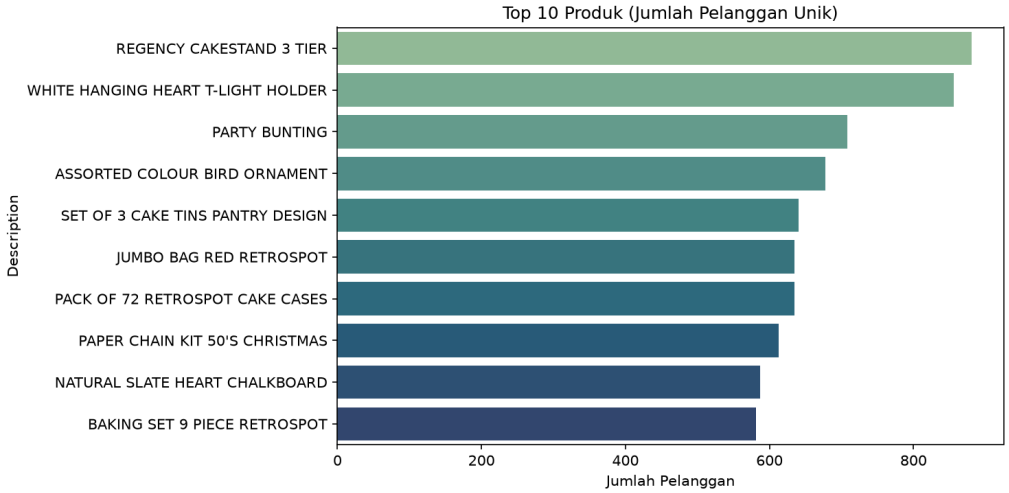
2.3. Eksplorasi Data Bersih

Distribusi jumlah invoice per pelanggan (Gambar 1) sangat condong ke kanan. Sebanyak 1.494 pelanggan (34,43%) hanya memiliki satu invoice, dan median jumlah invoice per pelanggan adalah 2. Artinya sepertiga pelanggan tidak dapat menghasilkan pola berurutan lintas transaksi, sehingga pola yang ditemukan terutama berasal dari pelanggan yang berbelanja berulang.



Gambar 1: Distribusi jumlah invoice per pelanggan (dipotong di 30)

Produk terpopuler diukur dari jumlah pelanggan unik (Gambar 2) adalah Regency Cakestand 3 Tier (sekitar 880 pelanggan), diikuti White Hanging Heart T-Light Holder (sekitar 855) dan Party Bunting (sekitar 705). Produk bertema dekorasi, dapur, dan musiman (Natal) mendominasi sepuluh teratas.



Gambar 2: Sepuluh produk teratas berdasarkan jumlah pelanggan unik

3. Pola Berurutan dan Evaluasi

3.1. Persiapan Sequence

Untuk menjaga ruang pencarian tetap terkelola, analisis dibatasi pada 100 produk teratas berdasarkan jumlah pelanggan unik. Setiap invoice diubah menjadi himpunan produk tanpa duplikat yang diurutkan secara alfabet. Invoice tiap pelanggan kemudian diurutkan menurut `InvoiceDate` dan digabung menjadi satu daftar produk. Hasilnya adalah 3.974 sequence pelanggan

3.2. Parameter Algoritma

Parameter	**Nilai**
Algoritma	PrefixSpan
Minimum support	1% dari pelanggan = 39 pelanggan
Panjang pola	1 sampai 2 item
Total pola frekuen	7.914 (100 pola panjang 1 dan 7.814 pola panjang 2)

Tabel 3: Konfigurasi dan hasil PrefixSpan

Untuk pola $A \rightarrow B$, metrik yang dihitung adalah:

- **Support** = jumlah pelanggan yang memiliki pola tersebut / total pelanggan (3.974).
- **Confidence** = jumlah pelanggan yang memiliki pola $A \rightarrow B$ / jumlah pelanggan yang membeli A.

3.3. Pola Teratas

Sepuluh pola teratas berdasarkan support ditampilkan pada Tabel 4. Sebagian pola berbentuk $A \rightarrow A$, yaitu pembelian ulang produk yang sama pada transaksi berikutnya.

Antecedent	**Consequent**	**Jumlah**	**Support (%)**	**Conf. (%)**
White Hanging Heart T-Light Holder	White Hanging Heart T-Light Holder	405	10,19	47,31
Regency Cakestand 3 Tier	Regency Cakestand 3 Tier	330	8,30	37,46
Paper Chain Kit 50's Christmas	Paper Chain Kit Vintage Christmas	321	8,08	52,37
Green Regency Teacup and Saucer	Roses Regency Teacup and Saucer	318	8,00	82,17
Jumbo Bag Red Retrospot	Jumbo Bag Red Retrospot	312	7,85	49,13
Regency Cakestand 3 Tier	Roses Regency Teacup and Saucer	299	7,52	33,94
Red Hanging Heart T-Light Holder	White Hanging Heart T-Light Holder	293	7,37	76,10
Lunch Bag Cars Blue	Lunch Bag Red Retrospot	293	7,37	61,17
Heart of Wicker Large	Heart of Wicker Small	292	7,35	60,21
Assorted Colour Bird Ornament	Assorted Colour Bird Ornament	291	7,32	42,92

Tabel 4: Sepuluh pola berurutan teratas berdasarkan support

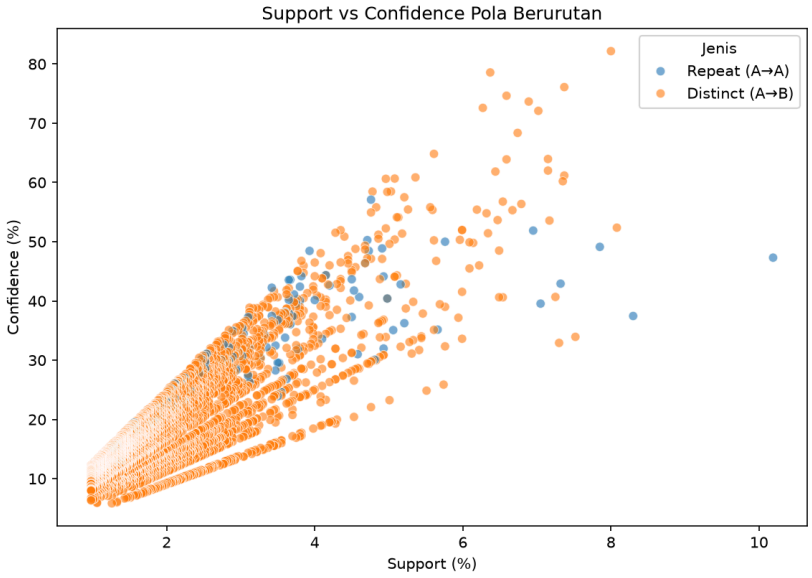
Karena pola $A \rightarrow A$ kurang informatif untuk rekomendasi lintas produk, dilakukan penyaringan khusus pola dengan produk berbeda (Tabel 5).

Antecedent	Consequent	Jumlah	Support (%)	Conf. (%)
Paper Chain Kit 50's Christmas	Paper Chain Kit Vintage Christmas	321	8,08	52,37
Green Regency Teacup and Saucer	Roses Regency Teacup and Saucer	318	8,00	82,17
Regency Cakestand 3 Tier	Roses Regency Teacup and Saucer	299	7,52	33,94
Red Hanging Heart T-Light Holder	White Hanging Heart T-Light Holder	293	7,37	76,10
Lunch Bag Cars Blue	Lunch Bag Red Retrospot	293	7,37	61,17
Heart of Wicker Large	Heart of Wicker Small	292	7,35	60,21
Regency Cakestand 3 Tier	Set of 3 Regency Cake Tins	290	7,30	32,92
Party Bunting	Spotty Bunting	288	7,25	40,68
Lunch Bag Red Retrospot	Lunch Bag Spaceboy Design	285	7,17	53,57
Lunch Bag Pink Polkadot	Lunch Bag Red Retrospot	284	7,15	63,96

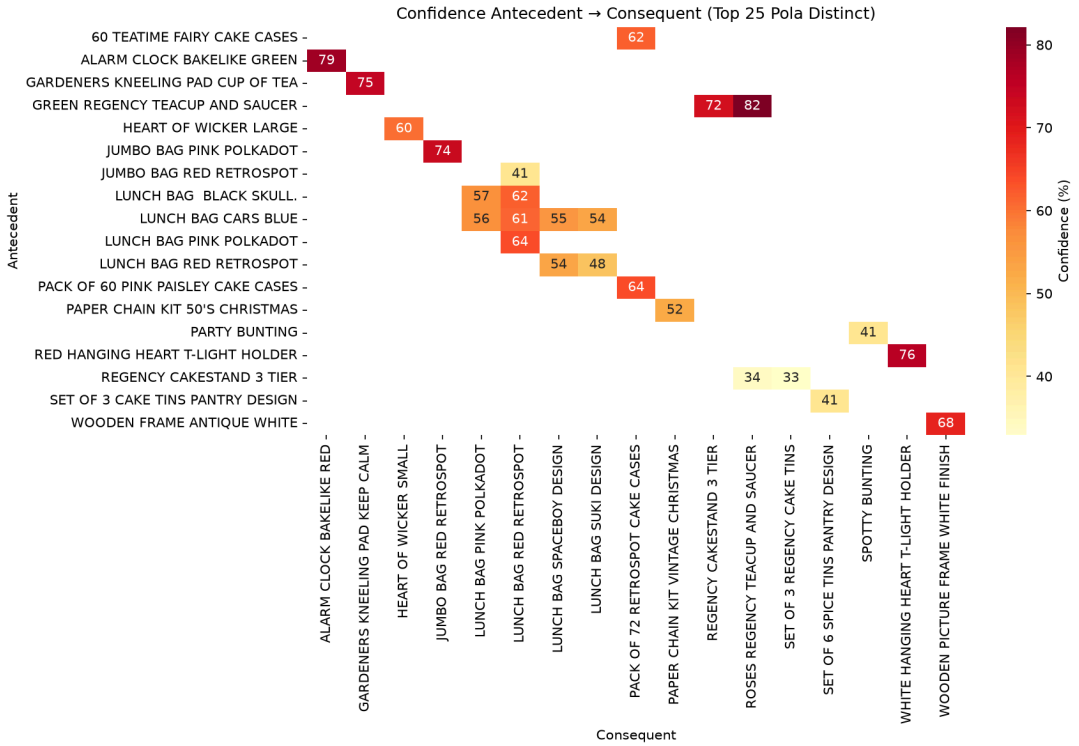
Tabel 5: Sepuluh pola berurutan teratas dengan produk berbeda

3.4. Visualisasi

Gambar 3 memperlihatkan hubungan support dan confidence seluruh pola panjang 2, dibedakan antara pola pembelian ulang (A→A) dan pola produk berbeda (A→B). Gambar 4 menunjukkan confidence pada 25 pola produk berbeda teratas.



Gambar 3: Support vs confidence pola berurutan



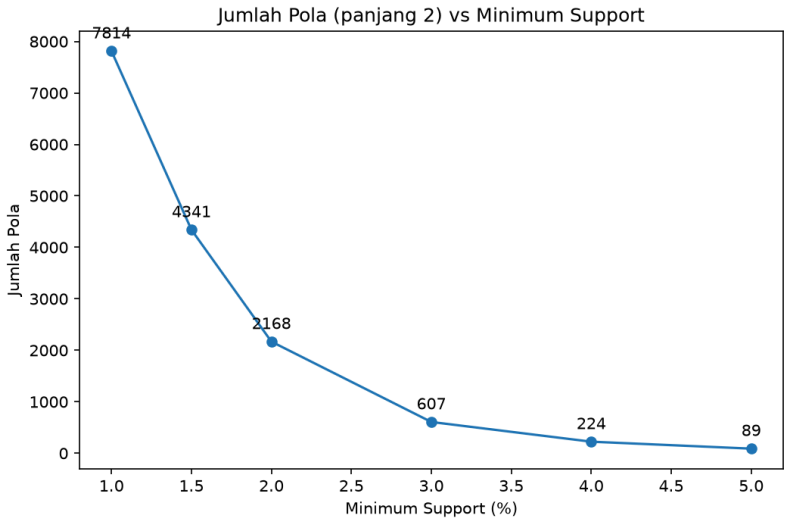
Gambar 4: Heatmap confidence antecedent ke consequent (25 pola distinct teratas)

3.5. Pengaruh Minimum Support

Percobaan dengan beberapa nilai minimum support menunjukkan jumlah pola panjang 2 turun tajam saat ambang dinaikkan (Gambar 5, Tabel 6).

Min. support (%)	Min. pelanggan	Jumlah pola
1,0	39	7.814
1,5	59	4.341
2,0	79	2.168
3,0	119	607
4,0	158	224
5,0	198	89

Tabel 6: Jumlah pola panjang 2 pada berbagai minimum support



Gambar 5: Jumlah pola (panjang 2) terhadap minimum support

Pada support 1% terdapat 7.814 pola, sementara pada 5% hanya 89 pola. Support 1% menghasilkan pola yang terlalu banyak untuk ditinjau manual, sedangkan 5% terlalu ketat dan membuang pola bermakna. Rentang 2% sampai 3% (607 sampai 2.168 pola) adalah kompromi yang lebih praktis bila hasil akan dipakai untuk rekomendasi.

3.6. Interpretasi Tiga Pola Terbaik (Produk Berbeda)

1. Paper Chain Kit 50′s Christmas → Paper Chain Kit Vintage Christmas (support 321 pelanggan atau 8,08%, confidence 52,37%). Sekitar 8% pelanggan membeli varian 50′s lalu varian Vintage, dan 52% pembeli varian 50′s menunjukkan pola ini. Pelanggan tampak mengoleksi beberapa motif untuk dekorasi Natal.

Rekomendasinya adalah bundle "Christmas Paper Chain Collection", promosi varian Vintage kepada pembeli varian 50′s, dan penyiapan stok kedua produk pada Oktober sampai Desember.

2. Green Regency Teacup and Saucer → Roses Regency Teacup and Saucer (support 318 pelanggan atau 8,00%, confidence 82,17%). Ini adalah confidence tertinggi di antara pola teratas: lebih dari empat dari lima pembeli varian Green juga memiliki varian Roses. Pelanggan kemungkinan ingin melengkapi koleksi Regency dengan motif berbeda.

Rekomendasinya adalah memasarkan lini Regency sebagai koleksi dan menampilkan fitur "Lengkapi Koleksi Anda" pada halaman produk.

3. Regency Cakestand 3 Tier → Roses Regency Teacup and Saucer (support 299 pelanggan atau 7,52%, confidence 33,94%). Pola ini mengindikasikan kebutuhan perlengkapan *afternoon tea*: cakestand untuk menyajikan kue, lalu cangkir bermotif senada. Confidence-nya lebih rendah karena cakestand adalah produk paling populer, sehingga pembelinya sangat beragam.

Rekomendasinya adalah paket "Afternoon Tea Set" yang menggabungkan kedua produk tersebut.

3.7. Evaluasi dan Keterbatasan

Beberapa hal perlu diperhatikan saat menilai hasil di atas.

- **Pola A→A** dapat mencerminkan pembelian ulang dan dapat menutupi pola lintas produk bila diurutkan murni berdasarkan support. Penyaringan produk berbeda sudah menanganinya.
- **Cakupan terbatas.** Hanya 100 produk teratas dan pola sepanjang maksimal 2 item yang dianalisis, sehingga pola yang melibatkan produk jarang atau lebih panjang tidak tertangkap.